# Ejercicio 06 · VAE, evaluación y Model Card

INF-8239 Ciencia de Datos II (UASD) · Unidad 03 · Consolidación de LAB10

| | |
|---|---|
| Estudiante | Edwing Perez |
| Profesor | Edwin Ramón José Nolasco |
| Repositorio | https://github.com/edvvdev/unidad04-06 |
| Dataset | Fashion-MNIST (Zalando) · licencia MIT · 60.000 entrenamiento + 10.000 prueba, 28×28 grises |
| Entorno | Python 3.12 · TensorFlow 2.21 · CPU (sin GPU detectada) · semilla 42 |
| Corrida de la evaluación | 2026-11-05 (fecha_ejecucion: 2026-11-05T22:52:47-05:00) |

## 1. Tabla principal de resultados

| Métrica | Autoencoder (AE) | VAE | Lectura |
|---|---|---|---|
| MSE de reconstrucción (1.000 de prueba) | 0,02048 | 0,03361 | El AE reconstruye mejor: la penalización KL compra espacio muestreable a costa de nitidez |
| Divergencia KL media | — | 6,3072 | El latente se aleja de la referencia N(0,1) |
| Tiempo de entrenamiento (s) | 6,63 | 13,50 | CPU de la corrida del 2026-11-05; contextual, no energía |
| Parámetros | 25.888 | 101.520 (decoder) | El decoder del VAE cuadruplica los parámetros del AE |
| Tamaño del modelo (KB) | 331 | 416 | Artefactos en models/, no versionados en Git |
| Diversidad media entre muestras (VAE) | — | 4,8769 | Distancia media entre 64 muestras del decoder, en el espacio de píxeles aplanados |
| Distancia media al vecino más cercano (VAE) | — | 3,3011 | Contra 1.000 imágenes del conjunto de prueba: no permite descartar la memorización |
| Línea base: distancia media entre pares de prueba | — | 11,3984 | Referencia del conjunto de prueba: es lo que hace interpretable la distancia al vecino más cercano |

Nota 1. Las tres métricas de muestreo (diversidad media, distancia al vecino más cercano y línea base de pares) aplican **solo al VAE**: el AE no tiene muestreador, solo reconstruye, por lo que su columna queda en «—».

Nota 2. Todas las cifras proceden de una única corrida (notebook ejecutado el 2026-11-05) y están en `reports/ejercicio06_metricas.json`, que es la única fuente de verdad de la entrega; por ejemplo, `distancia_media_entre_pares_de_prueba` = 11.3984 (en el texto se usa la coma decimal).

## Lectura canónica de diversidad y vecinos cercanos

Párrafo canónico de MODEL_CARD.md, citado literalmente en el cierre interpretativo y en este PDF.

> La diversidad media entre 64 muestras del decoder es **4,8769** (distancia media euclídea en el espacio de píxeles aplanados). La distancia media al vecino más cercano es **3,3011**, calculada **contra 1.000 imágenes del conjunto de prueba** y **no** contra el conjunto de entrenamiento: por eso **no permite descartar la memorización** y no es concluyente como indicador. La línea base es la distancia media entre pares de ese mismo conjunto de prueba, **11,3984** (`distancia_media_entre_pares_de_prueba`): con ella se ve que las muestras del decoder se concentran en una región más estrecha del espacio de píxeles que los datos reales (4,8769 frente a 11,3984), coherente con la repetición de patrones visible en el panel y con un espacio latente de solo 2 dimensiones, y que el 3,3011 se explica por esa concentración y no por una copia de una imagen de prueba.

## 2. Figuras

Figura 1. Panel de 16 ejemplos de prueba elegidos con semilla 42 (no seleccionados a mano): originales, reconstrucción AE, reconstrucción VAE y muestras nuevas del decoder.




Figura 2. Interpolación en el espacio latente de 2 dimensiones del VAE.

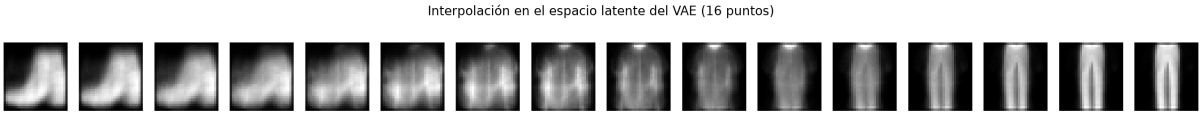
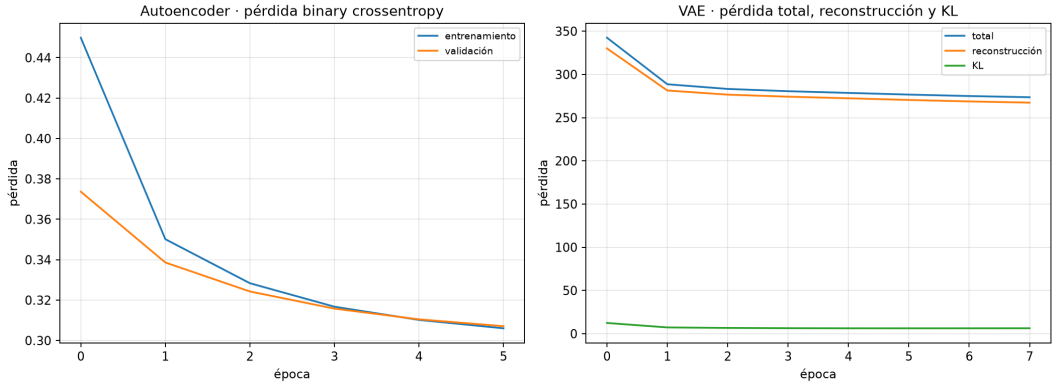



Figura 3. Curvas: pérdida del autoencoder (entrenamiento y validación) y del VAE (total, reconstrucción y KL).



## 3. Conclusión y decisión

La evidencia de diversidad y de vecinos cercanos se presenta en la Tabla 1 y en el párrafo canónico citado literalmente en la Model Card y en el cierre interpretativo (docs/CIERRE_INTERPRETATIVO_LAB10.md).

## Resultado de reconstrucción

El autoencoder reconstruye con **MSE 0,02048** sobre 1.000 ejemplos de prueba y el VAE con **MSE 0,03361** (`reports/ejercicio06_metricas.json`). El AE es mejor reconstructor: su cuello de botella de 16 unidades conserva suficiente información visual para el dominio de origen. El VAE pierde ~65 % más error de reconstrucción porque paga ese precio a cambio de un espacio latente muestreable (KL medio 6,3072). Las curvas (`reports/ejercicio06_curvas.png`) muestran la pérdida de entrenamiento (0,30604) y de validación (0,30710) prácticamente iguales en el AE: **no hay sobreajuste visible**; en el VAE la pérdida total se estabiliza (273,58) y la reconstrucción (267,33) y la KL (6,26) se mantienen en un equilibrio estable, sin que la penalización KL se dispare.

## Resultado de generación

El VAE **sí** genera: el decodificador produce imágenes distintas para puntos distintos del espacio latente (medias de píxel 0,104 para (0,0), 0,053 para (1,5,–1,0) y 0,505 para (–2,0,1,5), en `reports/ejercicio06_metricas.json`), y la interpolación entre dos extremos produce una transición continua (`reports/ejercicio06_interpolacion.png`). Pero la calidad es la de un benchmark didáctico: siluetas grises de 28×28, a veces reconocibles, a veces ambiguas. **Reconstruir bien y generar bien son tareas distintas**: el error de reconstrucción del AE no dice nada sobre la calidad de las muestras del VAE.

## Comportamiento del espacio latente

El espacio latente tiene **2 dimensiones**, suficiente para visualizar el decodificador pero demasiado estrecho para la variedad real de las prendas. Las proyecciones se agrupan y las interpolaciones son graduales pero no siempre plausibles: entre dos puntos las formas cambian de prenda de forma abrupta. Los ejes **no tienen interpretación semántica** (no son «tipo de prenda» ni «color»); lo que existe es la función que aprendió el decodificador.

## Costo computacional

| Elemento | Valor |
|---|---|
| Tiempo de entrenamiento AE (6 épocas) | 6,63 s |
| Tiempo de entrenamiento VAE (8 épocas) | 13,50 s |
| Parámetros AE / decoder | 25.888 / 101.520 |
| Tamaño `autoencoder.keras` / `decoder.keras` | 331 KB / 416 KB (se regeneran; no se versionan) |
| Hardware | CPU de escritorio, sin GPU (`scripts/check_runtime.py`: TensorFlow 2.21.0, `GPU: []`) |
| Entrenamiento total | 20,14 s; la aplicación solo hace inferencia |

## Riesgo o limitación

1. **Privacidad no garantizada:** una imagen sintética puede parecerse a un ejemplo de entrenamiento;

el análisis de vecinos cercanos de esta entrega se calculó contra el **conjunto de prueba**, de modo que **no permite descartar la memorización**. No se afirma privacidad.

2. **Sesgo heredado:** el modelo reproduce la distribución de Fashion-MNIST (ropa y calzado de

catálogo europeo); cualquier uso fuera de ese dominio es inválido.

3. **Fidelidad:** 28×28 en escala de grises; unsuitable para imágenes médicas, de vigilancia, de

documentos o de OCR.

4. **Espacio latente de 2 dimensiones:** limita la diversidad y hace que la interpolación sea una

demostración, no una herramienta de síntesis.

5. **Diversidad por debajo de la de los datos:** las 64 muestras del decoder están a 4,8769 entre sí,

frente a la línea base de 11,3984 de los datos de prueba. La concentración es compatible con un colapso parcial que la regularización KL (6,31) no evita.

## Decisión sobre uso previsto

Se **acepta** el uso del AE/VAE como material didáctico del Ejercicio 06: ilustrar qué es reconstruir, qué es muestrear y por qué un error bajo no garantiza generación plausible. Se **rechaza** cualquier uso que requiera originalidad, privacidad, diversidad o fidelidad: si se necesitara, el siguiente experimento es (1) aumentar el espacio latente a 16 dimensiones y repetir la comparación de KL, (2) repetir el análisis de vecinos cercanos **contra el conjunto de entrenamiento** y ampliar la línea base a los 10.000 ejemplos de prueba, y (3) marcar explícitamente toda salida sintética como tal en la interfaz y en el informe.

**Uso responsable de IA.** El asistente de IA apoyó la redacción de la Model Card, la extensión del script base para guardar curvas y métricas de reconstrucción y la construcción de este documento; los cambios están enumerados en `CAMBIOS_AL_BASE.md` y la declaración completa en `AI_USE_DECLARATION.md`. El estudiante conserva la responsabilidad sobre los datos, el código y estas conclusiones. Ninguna muestra generada se presenta como imagen real, original o libre de sesgo: el análisis de vecinos cercanos de esta entrega se calculó contra el conjunto de prueba y no contra el conjunto de entrenamiento, de modo que no permite descartar la memorización.