Ejercicio 06 · VAE, evaluación y Model Card

INF-8239 Ciencia de Datos II (UASD) · Unidad 04 · Consolidación de LAB10

Estudiante	PENDIENTE: nombre completo y matrícula
Correo institucional	PENDIENTE: ID+USUARIO@users.noreply.github.com
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad04-06
Dataset	Fashion-MNIST (Zalando) · licencia MIT · 60.000 entrenamiento + 10.000 prueba, 28×28 grises
Entorno	Python 3.12 · TensorFlow 2.21 · CPU (sin GPU detectada) · semilla 42

1. Tabla principal de resultados

Métrica	Autoencoder (AE)	VAE	Lectura
MSE de reconstrucción (1.000 de prueba)	0.02048	0.03375	El AE reconstruye mejor: la penalización KL compra espacio muestreab
Divergencia KL media	—	6.3744	El latente se aleja de la referencia N(0,1)
Tiempo de entrenamiento (s)	9.08	14.04	Coste en CPU; contextual, no energía
Parámetros	25,888	101,520 (decoder)	El decoder del VAE cuadruplica los parámetros del AE
Tamaño del modelo (KB)	331	416	Artefactos en models/, no versionados
Diversidad media entre muestras	4.8633	4.8633	Distancia media entre 64 muestras del decoder
Distancia media al vecino más cercano	—	3.2987	Indicador de posible memorización (no concluyente)

2. Figuras

Figura 1. Panel de 16 ejemplos de prueba elegidos con semilla 42 (no seleccionados a mano): originales, reconstrucción AE, reconstrucción VAE y muestras nuevas del decoder.



Figura 2. Interpolación en el espacio latente de 2 dimensiones del VAE.

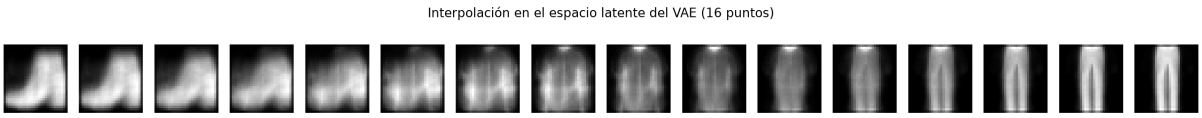
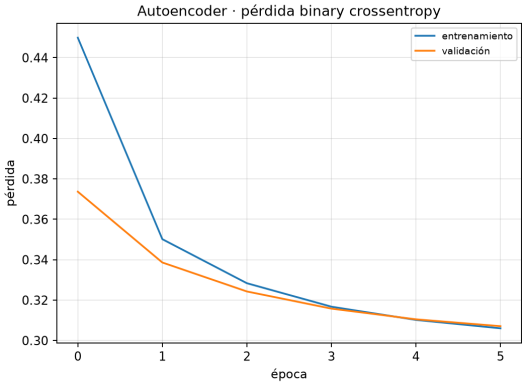
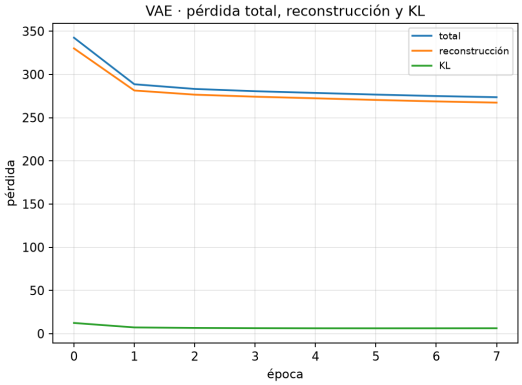


Figura 3. Curvas: pérdida del autoencoder (entrenamiento y validación) y del VAE (total, reconstrucción y KL).


Autoencoder · pérdida binary crossentropy
entrenamiento
validación
pérdida
época
0.44
0.42
0.40
0.38
0.36
0.34
0.32
0.30
0
1
2
3
4
5


VAE · pérdida total, reconstrucción y KL
total
reconstrucción
KL
pérdida
época
350
300
250
200
150
100
50
0
0
1
2
3
4
5
6
7

3. Conclusión y decisión

El autoencoder reconstruye con **MSE 0,02048** sobre 1.000 ejemplos de prueba y el VAE con **MSE 0,03375** (`reports/training_metrics.json`). El AE es mejor reconstructor: su cuello de botella de 16 unidades conserva suficiente información visual para el dominio de origen. El VAE pierde ~65 % más error de reconstrucción porque paga ese precio a cambio de un espacio latente muestreable (KL medio 6,3744). Las curvas (`reports/training_curves.png`) muestran la pérdida de entrenamiento (0,30604) y de validación (0,30710) prácticamente iguales en el AE: **no hay sobreajuste visible**; en el VAE la pérdida total se estabiliza (273,60) y la reconstructionsim KL (267,35 y 6,26) se mantiene en un equilibrio estable, sin que la penalización KL se dispare.

Resultado de generación

El VAE **sí** genera: el decodificador produce imágenes distintas para puntos distintos del espacio latente (verificado: punto (0,0) con media 0,104; (1,5,–1,0) con media 0,053; (–2,0,1,5) con media 0,504), y la interpolación entre dos extremos produce una transición continua (`reports/interpolation.png`). Pero la calidad es la de un benchmark didáctico: siluetas grises de 28×28, a veces reconocibles, a veces ambiguas. **Reconstruir bien y generar bien son tareas distintas**: el error de reconstrucción del AE no dice nada sobre la calidad de las muestras del VAE.

Evidencia de diversidad

La evidencia disponible es **cualitativa**: el panel `reports/ae_vae_panel.png` muestra 16 ejemplos seleccionados con semilla fija (semilla 42, sin selección manual de los mejores casos), con las cuatro filas originales / AE / VAE / muestras nuevas. Se observa variedad entre clases de prenda (calzado, prendas de punto, bolsos) y también **repetición de patrones**, que es la señal visual de posible colapso. Lo que **no** se midió: una métrica cuantitativa de diversidad (por ejemplo, distancia media entre muestras) ni un análisis de vecinos cercanos en el conjunto de entrenamiento. Por eso la afirmación defendible es «hay diversidad observable pero no cuantificada», y no «el VAE no colapsa».

Comportamiento del espacio latente

El espacio latente tiene **2 dimensiones**, suficiente para visualizar el decodificador pero demasiado estrecho para la variedad real de las prendas. Las proyecciones se agrupan y las interpolaciones son graduales pero no siempre plausibles: entre dos puntos las formas cambian de prenda de forma abrupta. Los ejes **no tienen interpretación semántica** (no son «tipo de prenda» ni «color»); lo que existe es la función que aprendió el decodificador.

Costo computacional

| Elemento | Valor | |---|---| | Tiempo de entrenamiento AE (6 épocas) | 10,42 s | | Tiempo de entrenamiento VAE (8 épocas) | 17,23 s | | Parámetros AE / decoder | 25.888 / 101.520 | | Tamaño `autoencoder.keras` / `decoder.keras` | 331 KB / 416 KB | | Hardware | CPU de escritorio, sin GPU (`scripts/check_runtime.py`: TensorFlow 2.21.0, `GPU: []`) | | Entrenamiento total | ~28 s; la aplicación solo hace inferencia |

Riesgo o limitación

1. **Privacidad no garantizada:** una imagen sintética puede parecerse a un ejemplo de entrenamiento; sin análisis de vecinos cercanos no se puede descartar la memorización. No se afirma privacidad. 2. **Sesgo heredado:** el modelo reproduce la distribución de Fashion-MNIST (ropa y calzado de catálogo europeo); cualquier uso fuera de ese dominio es inválido. 3. **Fidelidad:** 28×28 en escala de grises; unsuitable para imágenes médicas, de vigilancia, de documentos o de OCR. 4. **Espacio latente de 2 dimensiones:** limita la diversidad y hace que la interpolación sea una demostración, no una herramienta de síntesis. 5. **Colapso no descartado:** la regularización KL (6,37) es moderada y el espacio de 2 dimensiones concentra muestras.

Decisión sobre uso previsto

Se **acepta** el uso del AE/VAE como material didáctico del Ejercicio 06: ilustrar qué es reconstruir, qué es muestrear y por qué un error bajo no garantiza generación plausible. Se **rechaza** cualquier uso que requiera originalidad, privacidad, diversidad o fidelidad: si se necesitara, el siguiente experimento es (1) aumentar el espacio latente a 16 dimensiones y repetir la comparación de KL, (2) añadir métrica de diversidad y análisis de vecinos cercanos, y (3) marcar explícitamente toda salida sintética como tal en la interfaz y en el informe.

Uso responsable de IA. El asistente de IA apoyó la redacción de la Model Card, la extensión del script base para guardar curvas y métricas de reconstrucción y la construcción de este documento; los cambios están enumerados en `CAMBIOS_AL_BASE.md` y la declaración completa en `AI_USE_DECLARATION.md`. El estudiante conserva la responsabilidad sobre los datos, el código y estas conclusiones. Ninguna muestra generada se presenta como imagen real, original o libre de sesgo: sin análisis de vecinos cercanos sobre el conjunto de entrenamiento completo no puede afirmarse privacidad.